

Regresión Lineal y Regresión Múltiple

1. Descripción del dataset

Se utilizó un dataset propio, generado por la IA generativa DeepSeek, compuesto por 120 observaciones y las siguientes variables numéricas:

- Edad
- Experiencia
- Horas_Estudio
- Ingresos
- Gasto_Mensual
- Ahorro

La variable de estudio seleccionada fue **Ahorro**, ya que representa una variable económica que puede explicarse a partir de otras variables presentes en el conjunto de datos.

2. Regresión lineal simple

Para estudiar la correlación entre dos variables se aplicó una regresión lineal simple utilizando:

- Variable independiente: Ingresos
- Variable dependiente: Ahorro

Código

```
Datos1 <- read.csv("dataset_regresion_simple.csv")

modelo_simple <- lm(Ahorro ~ Ingresos, data = datos1)

summary(modelo_simple)

cor(datos1$Ingresos, datos1$Ahorro)
```

Gráfico de dispersión

```
plot(
  datos1$Ingresos,
  datos1$Ahorro,
  main = "Relación entre Ingresos y Ahorro",
  xlab = "Ingresos",
  ylab = "Ahorro",
  pch = 19
)
```

```
abline(modelo_simple,
       col = "red",
       lwd = 2)
```

Interpretación

La nube de puntos presenta una tendencia positiva. La recta de regresión indica que, en general, cuando aumentan los ingresos también aumenta el ahorro.

3. Selección de variables

Para identificar cuáles variables explican mejor el ahorro se utilizó el método Stepwise.

Código

```
library(MASS)

modelo_completo <- lm(
  Ahorro ~ Edad +
           Experiencia +
           Horas_Estudio +
           Ingresos +
           Gasto_Mensual,
  data = datos1
)

modelo_step <- stepAIC(
  modelo_completo,
  direction = "both"
)

summary(modelo_step)
```

Interpretación

El método Stepwise agrega o elimina variables automáticamente para obtener un modelo más eficiente, conservando únicamente aquellas que aportan información relevante para explicar el ahorro.

4. Regresión múltiple

Se construyeron dos modelos diferentes.

Modelo 1

Variables independientes:

- Ingresos
- Experiencia

```
modelo1 <- lm(  
  Ahorro ~ Ingresos + Experiencia,  
  data = datos1  
)
```

```
summary(modelo1)
```

Modelo 2

Variables independientes:

- Ingresos
- Experiencia
- Gasto_Mensual

```
modelo2 <- lm(  
  Ahorro ~ Ingresos +  
           Experiencia +  
           Gasto_Mensual,  
  data = datos1  
)
```

```
summary(modelo2)
```

5. Comparación de modelos

Para comparar ambos modelos se utilizaron:

- R^2
- R^2 Ajustado
- AIC

```
summary(modelo1)$r.squared  
summary(modelo2)$r.squared
```

```
summary(modelo1)$adj.r.squared  
summary(modelo2)$adj.r.squared
```

```
AIC(modelo1, modelo2)
```

Criterios

- Mayor R^2 Ajustado $\rightarrow$ mejor capacidad explicativa.
 - Menor AIC $\rightarrow$ mejor ajuste del modelo.
-

6. Gráfico de comparación de modelos

```
r2 <- c(
  summary(modelo1)$adj.r.squared,
  summary(modelo2)$adj.r.squared
)

barplot(
  r2,
  names.arg = c("Modelo 1", "Modelo 2"),
  main = "Comparación de Modelos",
  ylab = "R2 Ajustado"
)
```

7. Gráfico de valores reales vs predichos

Este gráfico permite observar la calidad de las predicciones realizadas por el modelo múltiple más completo.

```
pred <- predict(modelo2)

plot(
  datos$Ahorro,
  pred,
  main = "Valores reales vs predichos",
  xlab = "Ahorro real",
  ylab = "Ahorro predicho",
  pch = 19
)

abline(
  a = 0,
  b = 1,
  col = "red",
  lwd = 2
)
```

Interpretación

Cuanto más cercanos estén los puntos a la línea roja, mejor será la capacidad predictiva del modelo.

8. Conclusión

La regresión lineal simple mostró una relación positiva entre los ingresos y el ahorro.

Posteriormente, mediante el método Stepwise se identificaron las variables más relevantes para explicar el ahorro.

Se construyeron dos modelos de regresión múltiple. El segundo modelo incorporó la variable Gasto_Mensual además de Ingresos y Experiencia, obteniendo generalmente mejores indicadores de ajuste.

Por lo tanto, el Modelo 2 resulta más adecuado para explicar la variabilidad del ahorro dentro del conjunto de datos analizado.

Técnicas de Selección de Variables en Regresión Lineal Múltiple

La selección de variables es un proceso fundamental en la regresión lineal múltiple, ya que permite identificar cuáles variables independientes aportan información relevante para explicar la variable dependiente. Su objetivo es mejorar la capacidad predictiva del modelo, reducir la complejidad y evitar problemas como el sobreajuste (overfitting).

Las principales técnicas son las siguientes:

1. Selección Manual

Consiste en elegir las variables según el conocimiento previo del problema o criterio del investigador.

Ventajas

- Fácil de aplicar.
- Permite incorporar conocimiento del dominio.

Desventajas

- Puede introducir subjetividad.
 - Existe riesgo de excluir variables importantes.
-

2. Forward Selection (Selección hacia adelante)

El procedimiento comienza con un modelo vacío y agrega variables una por una.

Funcionamiento

1. Se inicia sin variables independientes.
2. Se incorpora la variable que más mejora el modelo.
3. Se continúa agregando variables mientras mejoren significativamente el ajuste.
4. El proceso finaliza cuando ninguna variable adicional aporta una mejora relevante.

Ventajas

- Menor costo computacional.
- Fácil interpretación.

Desventajas

- Puede ignorar combinaciones de variables importantes.
-

3. Backward Elimination (Eliminación hacia atrás)

Comienza con todas las variables disponibles y elimina progresivamente las menos significativas.

Funcionamiento

1. Se construye un modelo con todas las variables.
2. Se elimina la variable con menor significancia estadística.
3. Se recalcula el modelo.
4. El proceso continúa hasta que todas las variables restantes sean relevantes.

Ventajas

- Considera inicialmente toda la información disponible.

Desventajas

- Requiere una muestra relativamente grande.
 - Puede resultar costoso cuando existen muchas variables.
-

4. Stepwise Selection

Combina los métodos Forward y Backward.

Funcionamiento

- Agrega variables como en Forward Selection.

- Después de cada incorporación verifica si alguna variable existente debe eliminarse.
- Continúa hasta encontrar la mejor combinación posible.

Ventajas

- Es una de las técnicas más utilizadas.
- Suele producir modelos equilibrados entre simplicidad y precisión.

Desventajas

- Puede seleccionar modelos diferentes ante pequeñas variaciones en los datos.

Aplicación en el trabajo

En este trabajo se utilizó la función `stepAIC()` de R, que implementa una variante del método Stepwise basada en el criterio AIC.

5. Selección basada en Criterios de Información

Estos métodos comparan distintos modelos mediante indicadores estadísticos.

AIC (Akaike Information Criterion)

Evalúa simultáneamente:

- Calidad de ajuste.
- Complejidad del modelo.

Se prefiere el modelo con menor valor de AIC.

BIC (Bayesian Information Criterion)

Similar al AIC, pero penaliza más fuertemente la incorporación de variables adicionales.

Ventajas

- Permiten comparar múltiples modelos objetivamente.

Desventajas

- Requieren construir varios modelos para realizar la comparación.
-

6. Métodos de Regularización

Ridge Regression

Reduce el impacto de variables poco relevantes mediante una penalización sobre los coeficientes.

LASSO (Least Absolute Shrinkage and Selection Operator)

Además de penalizar los coeficientes, puede llevar algunos de ellos exactamente a cero, realizando selección automática de variables.

Elastic Net

Combina características de Ridge y LASSO.

Ventajas

- Muy útiles cuando existen muchas variables.
- Reducen problemas de multicolinealidad.

Desventajas

- Requieren ajustar parámetros adicionales.
-

Conclusión

Las técnicas más utilizadas para la selección de variables son Forward Selection, Backward Elimination y Stepwise Selection. En aplicaciones académicas y de tamaño moderado, Stepwise suele ser una de las opciones más prácticas debido a que combina la incorporación y eliminación de variables de forma automática.

Para este trabajo se utilizó el método Stepwise mediante la función `stepAIC()`, permitiendo identificar las variables que mejor explican la variable de estudio y construir modelos de regresión múltiple más eficientes.