

Ejercicio 2: Indicar si las siguientes afirmaciones son verdaderas o falsas. Debe justificar aquellas que considere falsas.

- El Big Data se caracteriza por su velocidad de procesamiento, pero no por su volumen. **ES FALSO, el Big Data se caracteriza por las 3 “V”; volumen, velocidad y variedad. O sea, se almacena mucha información, es veloz su acceso y procesamiento, y a su vez también posee diferentes tipos de formatos.**
- Los datos estructurados son la única forma de datos que se manejan en el Big Data. **ES FALSO, en Big Data también puede haber datos no estructurados.**
- Las herramientas tradicionales de gestión de bases de datos son suficientes para analizar datos de Big Data. **ES FALSO, no es suficiente las herramientas tradicionales, es por eso que hoy en día muchas empresas ofrecen soluciones más fáciles y optimizadas para analizar datos. Un ejemplo sería BigQuery.**
- El Big Data siempre implica la utilización de inteligencia artificial. **ES FALSO, el Big Data es previo al boom de la IA generativa, sin embargo hay herramientas de IA que facilitan su implementación y uso, pero no son necesarias si no se requiere.**
- HDFS (Hadoop Distributed File System) es un sistema de archivos centralizado que almacena todos los datos en un solo servidor. **ES FALSO, se caracteriza por almacenar archivos en un cluster de varias máquinas (servidores), permitiendo gestionar grandes volúmenes de datos que no caben en una sola.**

Ejercicio 3 ¿Cuál de los siguientes supuestos NO es necesario para la regresión lineal? Justificar su elección.

Los residuos deben tener una varianza constante.

La relación entre la variable dependiente y las variables independientes debe ser lineal.

Las variables independientes deben estar correlacionadas entre sí.

Los residuos deben tener una distribución normal.

"Las variables independientes deben estar correlacionadas entre sí" es la que NO es un supuesto necesario para la regresión lineal. Porque se procura evitar una alta correlación entre las variables independientes, ya que pueden generar problemas de multicolinealidad y afectar la estabilidad e interpretación del modelo.

Ejercicio 4 En una regresión lineal múltiple, ¿qué significa un valor p alto para un coeficiente de regresión específico?

La variable independiente correspondiente tiene un efecto significativo sobre la variable dependiente.

La variable independiente correspondiente no tiene un efecto significativo sobre la variable dependiente. La relación entre la variable dependiente y la variable independiente correspondiente es no lineal. Los datos no cumplen con los supuestos de la regresión lineal.

La varianza de los residuos es demasiado grande.

"La variable independiente correspondiente no tiene un efecto significativo sobre la variable dependiente." Es la respuesta. En una regresión lineal múltiple, el valor p (p-value) se utiliza para evaluar si el coeficiente asociado a

una variable independiente es significativamente diferente de cero. Si el valor p es alto (por ejemplo, mayor que 0,05), no existe evidencia estadística suficiente para rechazar la hipótesis nula. En ese caso, significaría que la variable no tiene un efecto significativo sobre la variable dependiente.